Diretrizes para a análise de dados

DEADLINE: 01/11/2026 às 23h59.

GRUPO: Essa atividade deve ser feita em grupos contendo **até 4 integrantes**. **IMPORTANTE:**

- A formação dos grupos é de responsabilidade dos alunos. A professora não irá atuar nessa questão.
- Cabe aos alunos gerenciar o andamento dos trabalhos em grupo. A professora não irá interferir em problemas decorrentes do relacionamento entre os membros dos grupos.
- Todos os integrantes do grupo são responsáveis pelo que for entregue, certifique-se de conhecer a versão final da análise de dados antes da entrega. **Os nomes dos integrantes devem estar na capa. NÃO SERÁ ACEITO ADICIONAR NOME DE ALUNO NA CAPA, APÓS ENTREGA.**

ENTREGA: Utilizando o link do enunciado da análise de dados dentro do Teams, anexar um arquivo com extensão docx **(não enviar PDF)** com o relatório e um arquivo com extensão R contendo o script construído para realização das análises necessárias. Para construção do relatório, atente-se as seguintes informações:

- O trabalho deverá ser entregue no formato de relatório ou texto acadêmico, não no formato de lista de exercício. Assim, clareza, organização, formatação, fluidez no texto e ortografia serão consideradas neste trabalho. Figuras, tabelas e gráficos devem ser numerados e corretamente citados no texto. Elementos não textuais que não forem analisados serão ignorados para fins de avaliação.
- Para realizar a atividade apresente tabelas, gráficos e demais técnicas estatísticas vistas em aula, que julgarem necessários.
- Análises incorretas e a apresentação de informações redundantes, por exemplo, uma tabela e um gráfico que transmitam exatamente a mesma informação serão penalizadas.
- O relatório deve ser autocontido e profissional, sendo importante apresentar e analisar as informações geradas, deixando códigos e saídas coladas do R (que não sejam tabelas ou gráficos) restritas ao script (que deve ser entregue obrigatoriamente), os elementos não textuais devem estar formatados adequadamente no relatório, evitando prints de códigos e console do R (exceto de gráficos e tabelas formatadas construídos no R).
- Gráficos, tabelas e medidas numéricas que estejam no *script*, mas não estejam no relatório serão desconsiderados. Ademais, códigos de gráficos, tabelas, medidas ou outros cujo resultado não apareça no relatório também serão ignorados.
- Atente-se para o envio correto dos DOIS documentos necessários dentro do prazo e pelo canal de envio correto (link do enunciado da análise de dados no Teams). Trabalhos enviados fora de prazo estão sujeitos a penalização da nota.
- Análises, discussões ou códigos muito além do que foi visto em sala serão penalizados.

Perfil de Risco e Consumo em Planos de Saúde

Operadoras de planos de saúde costumam monitorar o perfil de risco e de consumo de seus beneficiários, combinando características cadastrais com o histórico de uso do plano, para compreender melhor os fatores associados aos custos assistenciais.

Neste estudo, um analista de uma seguradora coletou informações de beneficiários de seus planos de saúde, incluindo características cadastrais e histórico de uso, com o objetivo de compreender melhor o perfil de risco e de consumo desses beneficiários.

No arquivo **saude_amostra.xlsx** são apresentadas as seguintes variáveis:

Idade – Idade do beneficiário, em anos;
Tempo_Plano_Meses – Tempo de vínculo com a operadora, em meses;
Qtd_Consultas_Ano – Número de consultas médicas realizadas no último ano [0 a 45];
Qtd_Internacoes_Ano – Número de internações hospitalares no último ano [0 a 8];
Custo_Anual_Operadora_K – Custo total do beneficiário para a operadora, em milhares de reais;
Mensalidade_K – Valor da mensalidade paga pelo beneficiário, em milhares de reais;
Tipo_Plano – Abrangência e cobertura do plano de saúde (Ambulatorial, Hospitalar, Referencia, Premium);
Regiao – Região geográfica do beneficiário no Brasil (Sudeste, Sul, Nordeste, CentroOeste, Norte);
Possui_Pre_Existencia – Indica se o beneficiário declarou doença pré-existente (Sim, Nao);
Canal_Aquisicao – Canal pelo qual o beneficiário contratou o plano (Corretor, Internet, Empresa, Loja);
Nivel_Sinistralidade – Percentual do custo do beneficiário em relação à mensalidade paga (Baixo, Medio, Alto);
Cancelou_Plano – Indica se o beneficiário cancelou o plano nos últimos 6 meses (Sim, Nao);
Perfil_Utilizacao – Padrão de uso do plano de saúde (Raramente, Ocasional, Frequente, Critico);

O objetivo é explorar o perfil de risco e consumo dos beneficiários de planos de saúde, investigando diferentes relações entre suas características cadastrais e seu histórico de uso do plano.

Baseando-se na leitura do texto e nos dados disponibilizados na planilha supracitada, responda:

Parte 1 – Validando a consistência dos dados

1.1 Classifique cada uma das variáveis da base de acordo com seu tipo.

1.2 Realize uma análise univariada para cada variável da base de dados. Isso ajudará a compreender as características gerais dos beneficiários representados e a identificar possíveis inconsistências nos dados, como valores aberrantes em variáveis quantitativas e rótulos descritos de maneiras diferentes ou erradas em variáveis qualitativas.

1.3 Sem observar os dados, quais variáveis (por exemplo, idade, região, canal de aquisição ou perfil de utilização) você esperaria que estivessem mais associadas ao nível de sinistralidade dos beneficiários? Justifique suas suposições iniciais.

Parte 2 – Tipo de plano e canal de aquisição estão associados?

2.1 Construa uma tabela cruzando o tipo de plano e o canal de aquisição dos beneficiários (frequências ou proporções). O tipo de plano contratado parece variar conforme o canal de aquisição? Interprete com base nos resultados.

Parte 3 – Uso do plano por nível de sinistralidade

3.1 Realize uma análise descritiva completa (medidas numéricas e gráficos) do custo anual para a operadora e da quantidade de consultas no ano, separando os beneficiários por nível de sinistralidade. Compare os resultados.

3.2 Existe indício de que o padrão de uso do plano está associado ao nível de sinistralidade? Interprete com base nos resultados.

Parte 4 – Há indícios de que o tempo de plano influencia a mensalidade?

4.1 Analise a relação entre o custo anual para a operadora e a quantidade de internações no ano. Há algum padrão relevante? Responda via gráfico e via alguma medida-resumo.

4.2 Investigue se a mensalidade paga pelo beneficiário parece variar com o tempo de vínculo com a operadora. Há algum padrão relevante?

Parte 5 – Doença pré-existente e sensibilidade do custo às consultas

Faça dois gráficos de dispersão entre o custo anual para a operadora e a quantidade de consultas no ano, um para os beneficiários com doença pré-existente e outro para os sem doença pré-existente. Inclua a equação da reta de regressão em cada gráfico.

Qual deveria ser o sinal esperado do coeficiente angular das retas de regressão nesse modelo? Utilize argumentos de saúde suplementar e, se desejar, referências bibliográficas adequadas para sua justificativa.

É possível indicar em qual dos dois grupos o custo é mais sensível à quantidade de consultas? Justifique sua resposta, articulando também com a análise descritiva das características de cada grupo.

O Erro Quadrático Médio (EQM) é uma medida de qualidade do ajuste da reta (quanto menor o EQM, melhor o ajuste). Neste caso, para calcularmos o EQM utilizaremos a seguinte fórmula:

$EQM = \Sigma\ (\hat{y}_i - y_i)^2,$ *somando para* $i = 1$ *até* n

onde $\hat{y}_i$ é o valor de o custo anual para a operadora previsto pela reta para a observação i, e y_i é o valor de o custo anual para a operadora observado. Calcule o EQM para ambas as retas estimadas. O que podemos afirmar sobre a qualidade do ajuste das retas?

Parte 6 – Explorando por conta própria

6.1 Formule você mesmo(a) uma pergunta adicional sobre os dados que não tenha sido contemplada nos itens anteriores, mas que julgue relevante para entender melhor o perfil de risco e consumo dos beneficiários. Utilize as ferramentas estatísticas vistas ao longo do curso (medidas-resumo, gráficos, regressão etc.) para respondê-la, e justifique tanto a escolha da pergunta quanto a análise realizada.